

Bayesian Learning

1. Gaussian PDF - Hàm mật độ xác suất

- giả định rằng mỗi đặc trưng của một vật, v.v đều tuân theo phân phối chuẩn (normal distribution) → khi ứng với đặc trưng đó bạn có một giá trị mới x_{new} , xác suất để giá trị này xuất hiện nếu nó thuộc về 1 class C (có trung bình μ và phương sai σ^2):

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

2. Naive Bayes Assumption

- nếu một vật có nhiều đặc trưng (vector $X = [x_1, x_2, \dots, X_n]$) thì làm sao để tính xác suất tổng thể?
- Naive → ngây thơ: các đặc trưng này hoàn toàn độc lập với nhau (giả định) → xác suất tổng thể nhờ giả định này đơn giản chỉ còn là Tích của các xác suất thành phần:

$$P(X|C) = \prod_{i=1}^n p(x_i|C) = p(x_1|C) \times p(x_2|C) \times \dots \times p(x_n|C)$$

- nếu số lượng features quá nhiều và xác suất mỗi đặc trưng đều rất nhỏ, khi nhân số lượng lớn này lại với nhau thì kết quả sẽ tiến sát về 0 → máy tính không thể lưu trữ số quá nhỏ, làm tròn thành 0 (lỗi overflow)
- để cứu vãn → dùng Logarit để biến phép nhân thành phép cộng

$$\log(A \times B) = \log(A) + \log(B)$$

$$\log P(X|C) = \sum_{i=1}^n \log(p(x_i|C))$$

3. Decision Rule

- Để biết vật thuộc class nào, ta phải tính điểm số cuối cùng kết hợp giữa xác suất thực tế đo được (likelihood) và tỉ lệ ngoài tự nhiên của vật đó (prior)

Điểm số Lớp $C = \text{XS thực tế (Prior)} \times \text{XS đo đạc (Likelihood)}$

- Áp dụng Logarit:

$$\text{Score}(C) = \log(P(C)) + \sum_{i=1}^n \log(p(x_i|C))$$

MAP - Maximum A Posteriori:

$$\hat{y} = \arg \max_C \left(\log P(C) + \sum_{i=1}^n \log p(x_i|C) \right)$$